

Análise Preditiva e Classificação Binária da Doença de Alzheimer: Uma Abordagem Multivariada sobre Dados Clínicos Tabulares e Comparação com o Estado da Arte

Flavio Grigorio dos Santos

Graduando em Engenharia de Computação

Instituto Federal de Educação, Ciência e Tecnologia de São Paulo (IFSP)

Campus Birigui

santos.flavio@aluno.ifsp.edu.br

Resumo: O diagnóstico precoce da Doença de Alzheimer (DA) é determinante para o retardo da progressão clínica e para o planejamento terapêutico, mas permanece dependente de avaliações especializadas de custo elevado. Este trabalho aborda o desafio de classificar pacientes a partir de dados clínicos tabulares de triagem, sem recorrer a neuroimagem. Utilizando o *Alzheimer's Disease Dataset*, aplicou-se um *pipeline* completo de pré-processamento, normalização Min-Max, análise exploratória, redução de dimensionalidade por PCA, clusterização (K-Means e GMM) e classificação supervisionada com seis algoritmos: KNN, SVM, Árvore de Decisão, Random Forest, Regressão Logística e Rede Neural (MLP). O Random Forest superou os demais modelos, alcançando acurácia de 94,23% ($\pm 1,04\%$) em validação cruzada estratificada de 10 *folds* e F1-Score de 0,86 no conjunto de testes. A análise de importância de atributos identificou a Avaliação Funcional, as Atividades de Vida Diária (ADL) e o MMSE como os preditores dominantes. O balanceamento da base em 50/50 por subamostragem elevou a revocação dos casos positivos de 0,79 para 0,95, reduzindo expressivamente os falsos negativos. Os resultados situam-se no patamar de trabalhos publicados sobre o mesmo conjunto de dados ($\sim 95\%$), confirmando que dados clínicos de triagem rápida, de baixo custo e não invasivos, podem sustentar um diagnóstico auxiliado por computador de alta acurácia.

Palavras-Chave: Doença de Alzheimer, Aprendizado de Máquina, Random Forest, Diagnóstico Auxiliado por Computador, Dados Clínicos Tabulares.

I. INTRODUÇÃO

A Doença de Alzheimer (DA) é o subtipo mais prevalente de demência e um dos maiores desafios de saúde pública das sociedades em envelhecimento. Caracteriza-se pela deterioração progressiva da memória, da função executiva e do comportamento, em decorrência da neurodegeneração associada ao acúmulo de placas beta-amiloides e emaranhados neurofibrilares de proteína tau. Por se tratar de uma condição sem cura estabelecida, mas com tratamentos capazes de retardar

seu curso, a detecção precoce assume valor clínico decisivo: identificar pacientes em estágios iniciais amplia a janela de intervenção e melhora o prognóstico funcional.

O diagnóstico auxiliado por computador (CAD, do inglês *Computer-Aided Diagnosis*) tem transformado essa área. A maior parte da literatura recente, contudo, concentra-se em dados de neuroimagem, sobretudo ressonância magnética estrutural, cuja aquisição é cara, demorada e indisponível em grande parte dos serviços de atenção primária. Persiste, assim, uma lacuna prática: a viabilidade de modelos preditivos acurados construídos exclusivamente sobre dados clínicos tabulares, tais como variáveis demográficas, hábitos de vida, histórico médico, exames laboratoriais e avaliações cognitivo-funcionais de triagem.

A classificação a partir desses dados não é trivial. Os atributos exibem grande heterogeneidade de escala e natureza (contínuos e categóricos), há sobreposição sintomática com outras demências e fronteiras difusas entre normalidade e comprometimento. Soma-se a isso o desbalanceamento típico de coortes clínicas, em que indivíduos sem o desfecho superam os casos positivos, o que se configura como uma fonte recorrente de modelos enviesados para a classe majoritária.

As contribuições deste artigo se dividem em: a realização de uma análise estatística descritiva detalhada das variáveis clínicas, evidenciando os marcadores cognitivo-funcionais como os de maior poder discriminante; a investigação da separabilidade das classes por meio de Análise de Componentes Principais (PCA, do inglês *Principal Component Analysis*) e de algoritmos de agrupamento não supervisionado (*K-Means* e GMM, do inglês *Gaussian Mixture Models*); a implementação e comparação rigorosa de seis classificadores sob os protocolos de *holdout* e validação cruzada estratificada (*stratified k-fold*); e a avaliação experimental do impacto do balanceamento de classes sobre a revocação (ou *recall*) dos casos positivos, métrica crítica em contexto médico.

II. TRABALHOS RELACIONADOS

A literatura recente sobre classificação automática da DA a partir de dados clínicos consolidou o *Alzheimer's Disease Dataset* de El Kharoua [4] como um *benchmark* público. Esta seção concentra-se nos trabalhos que utilizam esse mesmo conjunto de dados, permitindo uma comparação metodologicamente justa, e reserva as abordagens de neuroimagem como contraponto explícito para situar a contribuição deste estudo.

A. Modelos baseados no mesmo conjunto de dados

Os trabalhos sobre o *Alzheimer's Disease Dataset* convergem em dois pontos centrais: a predominância de modelos baseados em árvores e a identificação dos mesmos marcadores cognitivo-funcionais como preditores dominantes.

Bai [5] constitui o *benchmark* mais direto deste estudo. Empregando Random Forest com engenharia de atributos e seleção orientada por conhecimento de domínio, identificou um núcleo preditivo composto por ADL, avaliação funcional, MMSE e idade, atingindo acurácia de 94,95% e F1-Score de 0,9476 — patamar praticamente idêntico ao obtido neste trabalho, porém com etapas adicionais de engenharia de *features*.

Hossain *et al.* [6] alcançaram o desempenho mais elevado relatado sobre este conjunto. Construíram um *ensemble* de empilhamento (*stacking*) combinando Gradient Boosting e XGBoost, com Regressão Logística como meta-aprendiz, obtendo 97% de acurácia e AUC de 0,97. A análise SHAP apontou queixas de memória, MMSE, avaliação funcional, sintomas comportamentais, colesterol e fatores de estilo de vida como os atributos mais influentes — ranking que replica, com notável fidelidade, a importância de atributos encontrada no presente estudo.

Raghupathy *et al.* [7] investigaram esquemas de *boosting* (XGBoost, LightGBM e Gradient Boosting) acoplados a SHAP para seleção de atributos, demonstrando ser possível superar 94% de acurácia com um subconjunto mínimo de *features*. O estudo reforça a tese de que poucos marcadores cognitivo-funcionais concentram a maior parte do poder discriminante deste conjunto.

B. Síntese crítica e limitações dos trabalhos sobre o mesmo conjunto

Embora atinjam acurácias elevadas, esses trabalhos compartilham limitações que abrem espaço para a contribuição deste estudo. Primeiro, vários deles dependem de etapas de engenharia de atributos composta [5] ou de *ensembles* sofisticados [6], o que dificulta isolar a contribuição individual de cada componente do *pipeline* e reduz a reprodutibilidade. Segundo, a maioria trata o problema como classificação binária, sem dedicar atenção específica ao impacto do desbalanceamento sobre a revocação dos casos positivos, a métrica de maior relevância clínica, dado que falsos negativos representam diagnósticos perdidos. Terceiro, a comparação sistemática entre paradigmas distintos de classificação (lineares, baseados em distância, de margem e de *ensemble*) sob um protocolo único e transparente é pouco explorada.

C. Abordagens baseadas em neuroimagem

Para dimensionar a contribuição dos modelos clínicos, é útil contrastá-los com a vertente de neuroimagem, que utiliza dados de natureza distinta. Sarica *et al.* [2], em revisão sistemática, consolidaram o Random Forest como referência para a redução de dados de imagem de alta dimensionalidade. Estudos com volumes regionais derivados de ressonância magnética reportam acurácias da ordem de 90% [10]. O ponto crucial é que esse desempenho, inferior ao obtido sobre dados clínicos tabulares, é alcançado a um custo operacional substancialmente maior, exigindo exames de imagem indisponíveis em triagem de larga escala.

D. Posicionamento deste trabalho

Diante desse panorama, este estudo posiciona-se ao oferecer, sobre o mesmo *benchmark* público, um *pipeline* transparente e reprodutível que: (i) compara seis paradigmas de classificação sob protocolo idêntico de validação; (ii) isola experimentalmente o efeito do balanceamento de classes sobre a sensibilidade aos casos positivos; e (iii) atinge desempenho equivalente ao estado da arte (~94%) sem recorrer a engenharia de atributos sofisticada, confirmando, em consonância com [5], [6] e [7], a centralidade dos marcadores funcionais e cognitivos para a detecção da DA.

III. DESCRIÇÃO DO DATASET E ANÁLISE EXPLORATÓRIA DE DADOS

A. Origem e características

Empregou-se o *Alzheimer's Disease Dataset*, disponibilizado publicamente por Rabie El Kharoua [4]. Após a remoção de valores nulos e duplicatas, o conjunto compreende 2.149 pacientes e 35 atributos, abrangendo cinco domínios: informações demográficas (idade, gênero, etnia, escolaridade), hábitos de vida (tabagismo, consumo de álcool, atividade física, qualidade do sono e da dieta), histórico médico (doença cardiovascular, diabetes, depressão, hipertensão, traumatismo craniano, histórico familiar), exames laboratoriais (pressão arterial, perfil lipídico) e avaliações cognitivo-funcionais (MMSE, Avaliação Funcional, ADL) e sintomas reportados (queixas de memória, problemas comportamentais, confusão, desorientação).

A variável-alvo, Diagnóstico, é binária (0 = Sem Alzheimer; 1 = Com Alzheimer). A distribuição das classes é desbalanceada: 1.389 pacientes (64,6%) sem a doença e 760 (35,4%) com a doença, razão de aproximadamente 1,83:1 — fator a ser tratado na fase de modelagem.

B. Estatística descritiva

A faixa etária concentra-se entre 60 e 90 anos (média de 74,9 anos), distribuída de forma quase equilibrada entre os gêneros, com predominância da etnia caucasiana. A Tabela I sintetiza as medidas de tendência central e dispersão das principais variáveis contínuas.

A coincidência sistemática entre média e mediana indica distribuições aproximadamente simétricas, sem assimetrias graves. Destaca-se o elevado coeficiente de variação do MMSE

Tabela I
MEDIDAS DE RESUMO DAS PRINCIPAIS VARIÁVEIS CONTÍNUAS

Variável	Intervalo	Média	Mediana	Desvio	CV (%)
Idade	60–90	74,91	75,00	8,99	12,0
IMC	15–40	27,66	27,82	7,22	26,1
Pressão Sistólica	90–179	134,26	134,00	25,95	19,3
Pressão Diastólica	60–119	89,85	91,00	17,59	19,6
Colesterol Total	150–300	225,20	225,09	42,54	18,9
Colesterol LDL	50–200	124,34	123,34	43,37	34,9
Colesterol HDL	20–100	59,46	59,77	23,14	38,9
Triglicerídeos	50–400	228,28	230,30	101,99	44,7
MMSE	0–30	14,76	14,44	8,61	58,4
Aval. Funcional	0–10	5,08	5,09	2,89	56,9

(58,4%) e da Avaliação Funcional (56,9%): essa ampla dispersão relativa é o primeiro indício de que tais variáveis carregam informação discriminante substancial, pois espalham os pacientes ao longo de toda a escala em vez de concentrá-los em torno de um valor central.

Esse indício confirma-se na estratificação por classe. O MMSE médio cai de 16,27 nos pacientes sem Alzheimer para 11,99 nos diagnosticados; a Avaliação Funcional, de 5,86 para 3,65; e a ADL, de 5,71 para 3,66. Em todos os casos, o desempenho cognitivo-funcional é nitidamente inferior no grupo com a doença, em consonância com a fisiopatologia esperada.

C. Associação entre variáveis

A análise de correlação revelou um achado metodologicamente relevante. As variáveis contínuas exibem baixa correlação linear entre si, a correlação de Pearson entre MMSE e Avaliação Funcional é de apenas 0,025, indicando que medem dimensões independentes do comprometimento. Já a correlação com o desfecho é a esperada e clinicamente coerente: Avaliação Funcional (−0,365), ADL (−0,332) e MMSE (−0,237) correlacionam-se negativamente com o diagnóstico, ou seja, quanto menor o escore, maior a chance de Alzheimer.

Quanto aos sintomas binários, a prevalência diferencial é o que separa as classes. As Queixas de Memória saltam de 11,6% (sem DA) para 37,6% (com DA), e os Problemas Comportamentais, de 9,6% para 26,7%. Em contraste, fatores de risco clássicos como tabagismo (29,0% vs. 28,6%), histórico familiar (26,3% vs. 23,3%) e depressão (20,2% vs. 19,7%) apresentam prevalência praticamente idêntica entre os grupos, sinalizando, desde a EDA, que serão atributos de baixa importância preditiva neste conjunto.

D. Pré-processamento

O *pipeline* de preparação compreendeu: (i) remoção de valores nulos e duplicatas; (ii) descarte de atributos não informativos (identificador do paciente e médico responsável); (iii) normalização Min-Max das variáveis contínuas, preservando as categóricas em sua codificação original. Optou-se por reter o conjunto completo de atributos na etapa de classificação, evitando descartar precocemente os sintomas binários que, como mostrado, carregam sinal discriminante.

E. Redução de dimensionalidade

Aplicou-se a Análise de Componentes Principais (PCA) sobre as variáveis contínuas padronizadas, para inspecionar a separabilidade linear das classes. As duas primeiras componentes explicaram apenas 14,80% da variância total (7,42% e 7,38%), e as três primeiras, 21,90%. Essa baixíssima concentração de variância em poucos eixos tem dupla leitura: por um lado, indica ausência de estrutura linear dominante entre as variáveis contínuas; por outro, antecipa que as classes não são linearmente separáveis no subespaço contínuo, projeções 2D e 3D mostram forte sobreposição entre pacientes com e sem DA. Esse resultado é teoricamente importante, pois prenuncia o desempenho limitado de modelos lineares e o sucesso de modelos não lineares baseados em árvores, confirmado na Seção V. Vale notar que o sinal discriminante reside em grande parte nas variáveis categóricas (sintomas) e nos escores funcionais, não plenamente capturados por uma PCA restrita às contínuas.




Figura 1. Projeção dos pacientes sobre as duas primeiras componentes principais (PCA), que explicam em conjunto 14,80% da variância total. As classes (Diagnóstico: Não/Sim) exibem forte sobreposição, evidenciando a ausência de separabilidade linear no subespaço das variáveis contínuas.

F. Clusterização não supervisionada

A clusterização exploratória com K-Means ($k = 4$) e *Gaussian Mixture Model* ($n = 2$) sobre o espaço completo de *features* padronizadas reforçou esse diagnóstico. As tabelas de contingência entre os agrupamentos obtidos e o rótulo real não exibiram correspondência limpa: os clusters mesclam pacientes de ambas as classes, evidenciando que a estrutura natural dos dados, sem supervisão, não recupera espontaneamente a fronteira diagnóstica. Confirma-se, assim, a necessidade de aprendizado supervisionado para o problema.

IV. METODOLOGIA (PIPELINE DE CLASSIFICAÇÃO)

A. Atributos e protocolo de avaliação

A classificação utilizou todas as variáveis do conjunto (contínuas em escala Min-Max e categóricas). Adotou-se um

protocolo duplo de avaliação para garantir robustez: (i) *Holdout* com partição estratificada de 70% para treino e 30% para teste (645 amostras de teste); e (ii) Validação Cruzada Estratificada de 10 *folds* (StratifiedKFold, shuffle=True, random_state=42), reportando-se a acurácia média e o desvio-padrão entre os *folds*. A estratificação preserva a proporção das classes em cada partição, mitigando o viés de amostragem decorrente do desbalanceamento.

B. Modelos avaliados

Foram comparados seis classificadores, cobrindo paradigmas distintos:

- **KNN** (KNeighborsClassifier, $k = 5$): baseado em distância, sensível à escala e à dimensionalidade;
- **SVM** (kernel RBF): captura fronteiras não lineares via projeção em espaço de maior dimensão;
- **Árvore de Decisão**: modelo interpretável de partição recursiva;
- **Random Forest**: *ensemble* de árvores por *bagging*, robusto a ruído e capaz de modelar interações não lineares, particularmente adequado a dados clínicos heterogêneos;
- **Regressão Logística** (max_iter=1000): linha de base linear;
- **Rede Neural (MLP)**: arquitetura $32 \rightarrow 64$ (ReLU) $\rightarrow 32$ (ReLU) $\rightarrow 1$ (sigmoide), otimizador Adam, regularização L2 ($\alpha = 1 \times 10^{-4}$) e parada antecipada (*early stopping*).

A inclusão de modelos lineares (Regressão Logística), baseados em distância (KNN), de margem (SVM) e de *ensemble* (Random Forest) permite testar diretamente a hipótese, levantada na PCA, de que o problema exige fronteiras não lineares.

C. Métricas

Avaliaram-se acurácia, precisão, revocação e F1-Score. Em contexto médico, a revocação da classe positiva é a métrica crítica: um falso negativo significa deixar de identificar um paciente doente, omissão de consequências clínicas mais graves do que um falso positivo, que apenas encaminharia um paciente saudável a exame confirmatório. O F1-Score, média harmônica entre precisão e revocação, sintetiza o equilíbrio do modelo sob desbalanceamento.

V. RESULTADOS EXPERIMENTAIS

A. Desempenho comparativo dos modelos

A Tabela II apresenta o desempenho dos seis classificadores, ordenados por acurácia em validação cruzada.

O Random Forest liderou em todas as métricas, com 94,23% de acurácia em validação cruzada e baixo desvio-padrão (1,04%), indicando desempenho estável e não dependente de uma partição favorável. Os modelos baseados em árvore (Random Forest e Árvore de Decisão) destacaram-se do restante, confirmando empiricamente a previsão da análise exploratória: a estrutura não linear dos dados favorece particionamentos hierárquicos sobre fronteiras lineares ou métricas de distância. Coerentemente, os modelos lineares e de distância ficaram para trás, a Regressão Logística (83,48%) e, sobretudo, o KNN (71,75%), penalizado pela alta dimensionalidade e pela

Tabela II
DESEMPENHO COMPARATIVO DOS CLASSIFICADORES (BASE ORIGINAL)

Classificador	Acur. (HO)	F1 (HO)	Acur. (CV)	Desvio
Random Forest	0,9054	0,8635	0,9423	0,0104
Árvore de Decisão	0,8775	0,8351	0,8939	0,0084
SVM (RBF)	0,8109	0,7265	0,8455	0,0179
Regressão Logística	0,8155	0,7419	0,8348	0,0234
Rede Neural (MLP)	0,7907	0,6993	0,8283	0,0157
KNN ($k = 5$)	0,7132	0,5387	0,7175	0,0169

presença de variáveis categóricas, para as quais a distância euclidiana é pouco informativa. Notavelmente, a Rede Neural (82,83%) não superou os métodos de árvore, padrão recorrente em dados tabulares de porte moderado, em que *ensembles* de árvores costumam prevalecer sobre arquiteturas neurais.

B. Análise de erros: matriz de confusão

A matriz de confusão do Random Forest no *holdout* (base original) revela o efeito do desbalanceamento sobre os erros. Dos 417 pacientes sem DA, 407 foram corretamente classificados (apenas 10 falsos positivos); dos 228 com DA, 196 foram identificados, mas 32 escaparam como falsos negativos. Traduzido em métricas por classe: precisão de 0,95 e revocação de 0,79 para a classe positiva. Ou seja, embora o modelo seja altamente acurado, o desbalanceamento o torna conservador na detecção da doença — exatamente o erro mais indesejável em triagem clínica. Esse achado motiva o experimento da subseção seguinte.

C. Impacto do balanceamento de classes

Para mitigar os falsos negativos, balanceou-se a base em 50/50 por subamostragem (*undersampling*) da classe majoritária, retreinando o Random Forest com o conjunto completo de variáveis. A Tabela III confronta os dois cenários.

Tabela III
RANDOM FOREST: BASE ORIGINAL VS. BALANCEADA (50/50)

Cenário	Acur.	F1	Rev. (Com DA)	Acur. CV
Base original	0,905	0,86	0,79	0,942
Balanceada	0,943	0,94	0,95	0,938

O efeito foi expressivo. A revocação dos casos positivos subiu de 0,79 para 0,95, e o F1-Score, de 0,86 para 0,94, com acurácia global de 94,30% no teste e validação cruzada estável em 93,75% ($\pm 1,51\%$). A nova matriz de confusão equilibrou-se entre as classes: dos 228 pacientes com DA no teste, 216 foram corretamente detectados (apenas 12 falsos negativos, contra os 32 anteriores). O balanceamento, portanto, não apenas elevou as métricas agregadas, mas redistribuiu o desempenho de forma clinicamente apropriada. O modelo deixou de privilegiar a classe majoritária e passou a detectar a doença com sensibilidade de 95%.

D. Importância dos atributos

A análise de importância de *features* do Random Forest explicita os fundamentos da decisão do modelo. A Tabela IV lista os principais preditores.

Tabela IV
IMPORTÂNCIA DOS ATRIBUTOS (RANDOM FOREST)

Atributo	Importância
Avaliação Funcional	0,177
ADL (Atividades de Vida Diária)	0,155
MMSE	0,121
Queixas de Memória	0,077
Problemas Comportamentais	0,044
Triglicérides	0,034

Os três primeiros atributos, todos marcadores cognitivo-funcionais, concentram aproximadamente 45% da importância total do modelo, seguidos pelos sintomas reportados. Os fatores de risco demográficos e de estilo de vida tiveram contribuição marginal, confirmando quantitativamente o que a EDA antecipara: neste conjunto, a deterioração funcional e cognitiva mensurável é o que separa as classes, não os fatores de risco históricos.

VI. DISCUSSÃO E COMPARAÇÃO COM A LITERATURA

A. Interpretação das descobertas

A superioridade do Random Forest articula-se diretamente com a natureza dos dados. A PCA demonstrou ausência de separabilidade linear no subespaço contínuo, e a clusteração não supervisionada falhou em recuperar a fronteira diagnóstica, nesse cenário, um *ensemble* de árvores, capaz de modelar interações não lineares e de tratar nativamente atributos categóricos, encontra terreno ideal, ao passo que modelos lineares e baseados em distância são estruturalmente limitados. A hierarquia de importância de *features* fornece a explicabilidade exigida de um modelo médico: a decisão do classificador apoia-se em Avaliação Funcional, ADL e MMSE, instrumentos consagrados na prática clínica, o que confere plausibilidade fisiopatológica às predições e facilita a aceitação por profissionais de saúde.

B. Comparação direta com o estado da arte

A Tabela V confronta os resultados obtidos com trabalhos representativos.

A comparação sustenta duas conclusões. Primeiro, a convergência com os trabalhos que utilizam o mesmo conjunto de dados é notável: Bai [5] reportou 94,95% / F1 0,9476 e o *ensemble* explicável [6] reportou 95% / F1 0,94, valores estatisticamente indistinguíveis dos 94,30% / F1 0,94 aqui obtidos, e alcançados sem a engenharia de atributos composta de [5] nem a otimização sofisticada de [6]. Essa equivalência valida a robustez do *pipeline* proposto e sugere que o teto de desempenho neste conjunto é determinado mais pela informação intrínseca dos dados do que pela sofisticação

Tabela V
COMPARAÇÃO COM A LITERATURA

Estudo	Dados	Modelo	Acur.	F1/Rev.
Este trabalho (balanc.)	Clínicos tabulares (mesma base)	Random Forest	94,30%	0,94/0,95
Bai [5]	Clínicos tabulares (mesma base)	RF + eng. <i>features</i>	94,95%	0,9476
Ens. explic. [6]	Clínicos tabulares (mesma base)	RF + SMOTE	95,0%	0,94/0,94
Sarica [10]	Neuroimagem (ADNI MRI)	RF/MLP/CNN	~90%	—
Yi [8]	Clínicos (ADNI/NACC)	XGBoost-SHAP	87,6%	AUC 0,91

do modelo. Segundo, e crucialmente, os modelos clínicos tabulares igualam ou superam os de neuroimagem (~90% em [10]) a uma fração do custo: prescindem de ressonância magnética e dependem apenas de instrumentos de triagem aplicáveis em consultório.

Reforça essa leitura a concordância sobre os preditores dominantes: tanto este trabalho quanto Bai [5], o *ensemble* explicável [6] (via SHAP) e análises independentes de importância sobre o mesmo conjunto convergem para Avaliação Funcional, ADL, MMSE e Queixas de Memória como os atributos mais influentes. Essa replicação do ranking de importância por equipes e métodos distintos confere solidez à hipótese clínica subjacente.

C. Significância clínica

O valor prático do *pipeline* reside na triagem de baixo custo. Um modelo que atinge 94% de acurácia e 95% de sensibilidade usando exclusivamente dados de avaliação clínica e cognitiva rápida pode operar como ferramenta de primeira linha na atenção primária, sinalizando os pacientes que devem ser priorizados para investigação especializada e neuroimagem confirmatória. A ênfase na revocação, obtida via balanceamento, alinha o modelo ao objetivo clínico de minimizar diagnósticos perdidos.

D. Limitações do estudo

A honestidade científica exige reconhecer as limitações. Primeiro, a coorte concentra-se em uma faixa etária restrita (60–90 anos) e em predominância de uma etnia, o que limita a generalização e introduz risco de viés de seleção. Segundo, o problema foi tratado como classificação binária (com/sem DA), não contemplando o estágio intermediário de Comprometimento Cognitivo Leve (MCI), fronteira reconhecidamente mais difícil e clinicamente decisiva, abordada em trabalhos multiclasse como [8]. Terceiro, a estratégia de balanceamento por subamostragem descarta parte dos dados da classe majoritária; embora eficaz aqui, técnicas de sobreamostragem como SMOTE [6] poderiam preservar a totalidade da informação. Por fim, os dados são transversais, impedindo a modelagem da progressão temporal da doença.

VII. CONCLUSÕES E TRABALHOS FUTUROS

Este trabalho desenvolveu e avaliou um *pipeline* completo de ciência de dados para a classificação binária da Doença de Alzheimer sobre dados clínicos tabulares, partindo do pré-processamento e da análise exploratória até a classificação supervisionada e o tratamento do desbalanceamento. Respondendo categoricamente ao problema proposto na introdução: é viável construir um classificador de alta acurácia para a DA usando exclusivamente dados de triagem clínica de baixo custo. O Random Forest mostrou-se o modelo preferencial, com 94,23% de acurácia em validação cruzada, e o balanceamento da base elevou a sensibilidade aos casos positivos a 95%, reduzindo os falsos negativos a um patamar clinicamente aceitável. A análise exploratória, da dispersão das variáveis cognitivas à ausência de separabilidade linear na PCA, antecipou e fundamentou cada resultado da modelagem, e a importância dos atributos confirmou a centralidade dos marcadores funcionais e cognitivos, em plena concordância com o estado da arte sobre o mesmo conjunto de dados.

Como trabalhos futuros, vislumbram-se quatro direções: (1) estender o problema para a classificação multiclasse incorporando o estágio de MCI, ampliando a utilidade clínica para o diagnóstico diferencial precoce; (2) validar o modelo em coortes externas e demograficamente diversas, testando sua generalização; (3) aplicar arcabouços de explicabilidade como SHAP e LIME para fornecer justificativas individualizadas por paciente, requisito para adoção clínica; e (4) desenvolver um módulo de interface web que permita a médicos inserir dados de triagem e obter, em tempo real, uma estimativa de risco interpretável.

REFERÊNCIAS

- [1] Alzheimer's Association, "2025 Alzheimer's disease facts and figures," *Alzheimer's & Dementia*, vol. 21, no. 4, e70235, 2025.
- [2] A. Sarica, A. Cerasa, and A. Quattrone, "Random forest algorithm for the classification of neuroimaging data in Alzheimer's disease: A systematic review," *Frontiers in Aging Neuroscience*, vol. 9, art. 329, Oct. 2017.
- [3] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [4] R. El Kharoua, "Alzheimer's disease dataset," Kaggle, 2024. [Online]. Available: <https://doi.org/10.34740/KAGGLE/DSV/8668279>
- [5] Y. Bai, "Diagnosis and prediction model for Alzheimer's disease based on random forest algorithm," *Frontiers in Computing and Intelligent Systems*, vol. 15, no. 1, pp. 18–22, Jan. 2026.
- [6] M. S. Hossain *et al.*, "Optimizing Alzheimer's disease prediction through ensemble learning and feature interpretability with SHAP-based feature analysis," *Alzheimer's & Dementia: Diagnosis, Assessment & Disease Monitoring*, vol. 17, no. 3, e70162, 2025.
- [7] B. K. Raghupathy, M. R. Reddy, P. Theeda, E. Balasubramanian, R. K. Namachivayam, and M. Ganesan, "Harnessing explainable artificial intelligence (XAI) based Shapley values and ensemble techniques for accurate Alzheimer's disease diagnosis," *Engineering, Technology & Applied Science Research*, vol. 15, no. 2, pp. 20743–20747, Apr. 2025.
- [8] F. Yi, H. Yang, D. Chen, Y. Qin, H. Han, J. Cui, W. Bai, Y. Ma, R. Zhang, and H. Yu, "XGBoost-SHAP-based interpretable diagnostic framework for Alzheimer's disease," *BMC Medical Informatics and Decision Making*, vol. 23, art. 137, Jul. 2023.
- [9] "Performance-optimized Alzheimer's detection using machine learning with SMOTE and randomized hyperparameter tuning," *Discover Artificial Intelligence*, 2025. [Online]. Available: <https://doi.org/10.1007/s44163-025-00758-z>
- [10] A. V. Lebedev, E. Westman, G. J. P. Van Westen *et al.*, "Random forest ensembles for detection and prediction of Alzheimer's disease with a good between-cohort robustness," *NeuroImage: Clinical*, vol. 6, pp. 115–125, 2014.
- [11] F. Pedregosa, G. Varoquaux, A. Gramfort *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.